ΠΑΝΕΠΙΣΤΗΜΙΟ ΠΕΙΡΑΙΩΣ
UNIVERSITY OF PIRAEUS

Εξεταζόμενο μάθημα: Εξόρυξη και Προετοιμασία Δεδομένων

ΣΥΣΤΗΜΑ ΚΑΤΗΓΟΡΙΟΠΟΙΗΣΗΣ ΚΕΙΜΕΝΩΝ ΓΙΑ ΑΝΑΛΥΣΗ ΣΥΝΑΙΣΘΗΜΑΤΟΣ ΣΕ IMDBS REVIEWS

ΟΝΟΜΑΤΕΠΩΝΥΜΟ: ΜΑΡΙΛΕΝΑ ΚΑΣΙΟΥΜΗ-ΔΗΜΗΤΡΑ ΣΥΚΕΡΙΔΗ
ΑΜ: ΜΕ25016- ΜΕ25036
ΠΜΣ : Πληροφοριακά Συστήματα και Υπηρεσίες
ΚΑΤΕΥΘΥΝΣΗ: Μεγάλα Δεδομένα και Αναλυτική
ΔΙΔΑΣΚΩΝ ΚΑΘΗΓΗΤΗΣ: ΧΑΛΚΙΔΗ ΜΑΡΙΑ
ΑΚΑΔΗΜΑΙΚΟ ΕΤΟΣ :2025-2026
ΗΜΕΡΟΜΗΝΙΑ ΠΑΡΑΔΟΣΗΣ: 08/02/2026

Περιεχόμενα

Εισαγωγή 2

Περιγραφή Σύνολού Δεδομένων 3

Προεπεξεργασία Κειμένου 4

Εξαγωγή Χαρακτηριστικών 6

Μοντέλα Κατηγοριοποίησης 8

Χρήση Cross-Validation για αξιολόγηση των μοντέλων 12

Συγκριτική Ανάλυση 14

Συμπεράσματα και Μελλοντική Εργασία 14

Εισαγωγή

Στην παρούσα εργασία, παρουσιάζεται η ανάπτυξη ενός ολοκληρωμένου συστήματος ανάλυσης συναισθήματος (sentiment analysis) για κριτικές ταινιών. Η υλοποίηση αυτή βασίζεται στο σύνολο δεδομένων IMDb Reviews το οποίο είναι διαθέσιμο στην ιστοσελίδα του Kaggle. Στόχος της εργασίας είναι η μελέτη και υλοποίηση ολόκληρης της αλυσίδας επεξεργασίας κειμένου, ξεκινώντας από την εξερεύνηση και τον καθαρισμό των δεδομένων , συνεχίζοντας με την εξαγωγή χαρακτηριστικών και την εκπαίδευση μοντέλων και καταλήγοντας στην αξιολόγηση και σύγκριση διαφορετικών προσεγγίσεων κατηγοριοποίησης.

Για την επίτευξη του στόχου αυτού, εφαρμόζεται μια μεθοδολογία μηχανικής μάθησης που περιλαμβάνει προεπεξεργασία κειμένου, εξαγωγή χαρακτηριστικών και εκπαίδευση μοντέλων ταξινόμησης. Για τον σκοπό αυτό εξετάζονται τόσο ένα βασικό γραμμικό μοντέλο (Logistic Regression) όσο και ένα πιο προχωρημένο ensemble μοντέλο (XGBoost), ενώ η απόδοση αξιολογείται με κατάλληλα metrics και με χρήση διασταυρωμένης επικύρωσης (cross-validation), ώστε να διασφαλιστεί η αξιοπιστία και η γενίκευση των αποτελεσμάτων.

Περιγραφή Σύνολού Δεδομένων

Το σύνολο δεδομένων IMDb Reviews, πάνω στο οποίο υλοποιήθηκε η εργασία, περιλαμβάνει συνολικά 100.000 κριτικές ταινιών καθεμία από τις οποίες συνοδεύεται από ετικέτα συναισθήματος (label). Οι διαθέσιμες ετικέτες είναι οι εξής: θετική (positive), αρνητική (negative) και μη επιβλεπόμενη (unsupervised).

Στο πλαίσιο της παρούσας εργασίας, το ενδιαφέρον επικεντρώνεται στη δυαδική επιβλεπόμενη κατηγοριοποίηση συναισθήματος. Για τον λόγο αυτό, τα μη επιβλεπόμενα δείγματα αφαιρέθηκαν και διατηρήθηκαν μόνο οι θετικές και αρνητικές κριτικές κατά την εκπαίδευση του αλγορίθμου. Για την εκπαίδευση του αλγορίθμου, το τελικό σύνολο δεδομένων αποτελείται από 50.000 κριτικές, εκ των οποίων οι 25.000 είναι θετικές και οι 25.000 αρνητικές.

Η κατανομή των ετικετών παρουσιάζεται στον Πίνακα 1 και είναι απολύτως ισορροπημένη. Η ισορροπία αυτή είναι ιδιαίτερα σημαντική καθώς επιτρέπει τη χρήση μετρικών όπως η ακρίβεια (accuracy), η precision, η recall και το F1-score χωρίς να υπάρχει μεροληψία υπέρ κάποιας κυρίαρχης κλάσης.

Πίνακας Α: Κατανομή ετικετών στο σύνολο δεδομένων IMDb

Ετικέτα	**Πλήθος κριτικών**
Αρνητικές (negative)	25.000
Θετικές (positive)	25.000
Σύνολο	50.000

Ο Πίνακας Α παρουσιάζει την τελική κατανομή των ετικετών συναισθήματος μετά την αφαίρεση των μη επιβλεπόμενων δειγμάτων. Παρατηρείται πλήρης ισορροπία μεταξύ θετικών και αρνητικών κριτικών, γεγονός που καθιστά το σύνολο δεδομένων κατάλληλο για δίκαιη και αξιόπιστη αξιολόγηση των μοντέλων κατηγοριοποίησης.

Προεπεξεργασία Κειμένου

3.1 Αρχική διερεύνηση και εντοπισμός θορύβου στα δεδομένα

Αρχικό στάδιο πριν την εκπαίδευση των τελικών αλγορίθμων είναι η προεπεξεργασία των δεδομένων. Η αρχική διερεύνηση των δεδομένων έδειξε ότι τα ακατέργαστα κείμενα των κριτικών περιέχουν σημαντικό θόρυβο.

Συγκεκριμένα, εντοπίστηκαν σε HTML tags (58.813 reviews), σημεία στίξης, ειδικοί χαρακτήρες (99.996 reviews) και μεγάλος αριθμός stopwords (99.999 reviews). Επιπλέον, οι κριτικές είναι ιδιαίτερα εκτενείς και περιγραφικές, γεγονός που οδηγεί σε αυξημένη παρουσία μη πληροφοριακών λέξεων.

Η ανάλυση της συχνότητας των stopwords έδειξε ότι κάθε κριτική περιέχει κατά μέσο όρο περισσότερες από 100 λέξεις αυτής της κατηγορίας, με μεγάλη διακύμανση μεταξύ των δειγμάτων. Το εύρημα αυτό καταδεικνύει ότι χωρίς κατάλληλο καθαρισμό η αναπαράσταση του κειμένου θα περιείχε σημαντικό θόρυβο επηρεάζοντας αρνητικά την απόδοση των μοντέλων.

Επομένως,συνοπτικά εντοπίστηκαν:

- HTML tags: 58.813 reviews
- Σημεία στίξης & ειδικοί χαρακτήρες: παρόντα σε 99.996 reviews
- Stopwords: σχεδόν καθολική παρουσία (99.999 reviews)
- Η κατανομή του πλήθους stopwords έδειξε: μέσος όρος ≈ 105 stopwords ανά review με μέγιστη τιμή 1.061 stopwords

3.2 Καθαρισμός και Κανονικοποίηση Κειμένου

Με βάση τα παραπάνω προχωρήσαμε σε μια ολοκληρωμένη διαδικασία προ επεξεργασίας κειμένου. Τα βασικά βήματα περιλαμβάνουν την αφαίρεση URLs και HTML tags, τη μετατροπή όλων των χαρακτήρων σε πεζά, την απομάκρυνση σημείων στίξης και ειδικών χαρακτήρων καθώς και την κανονικοποίηση των κενών. Στη συνέχεια, πραγματοποιήθηκε αφαίρεση stopwords, με εξαίρεση λέξεις άρνησης όπως not, no και never, οι οποίες είναι κρίσιμες για τη σωστή απόδοση του συναισθήματος.

Τέλος, εφαρμόστηκε (lemmatization) με χρήση του WordNet ώστε να μετατραπούν διαφορετικές μορφές της ίδιας λέξης στη βασική τους μορφή. Η διαδικασία αυτή συμβάλλει στη μείωση της πολυπλοκότητας του λεξιλογίου και στη βελτίωση της γενίκευσης των μοντέλων.

```
ORIGINAL:
 Not even the Beatles could write songs everyone liked, and although Walter Hill is no mop-top he's second to none when it comes to thought provoking act
ion movies. The nineties came and social platforms were changing in music and film, the emergence of the Rapper turned movie star was in full swing, the
acting took a back seat to each man's overpowering regional accent and transparent acting. This was one of the many ice-t movies i saw as a kid and love
d, only to watch them later and cringe. Bill Paxton and William Sadler are firemen with basic lives until a burning building tenant about to go up in fla
mes hands over a map with gold implications. I hand it to Walter for quickly and neatly setting up the main characters and location. But i fault everyone
involved for turning out Lame-o performances. Ice-t and cube must have been red hot at this time, and while I've enjoyed both their careers as rappers, i
n my opinion they fell flat in this movie. It's about ninety minutes of one guy ridiculously turning his back on the other guy to the point you find your
self locked in multiple states of disbelief. Now this is a movie, its not a documentary so i wont waste my time recounting all the stupid plot twists in
this movie, but there were many, and they led nowhere. I got the feeling watching this that everyone on set was sord of confused and just playing things
off the cuff. There are two things i still enjoy about it, one involves a scene with a needle and the other is Sadler's huge 45 pistol. Bottom line this
movie is like domino's pizza. Yeah ill eat it if I'm hungry and i don't feel like cooking, But I'm well aware it tastes like crap. 3 stars, meh.

CLEAN:
 not even beatles could write songs everyone like although walter hill no mop top second none come think provoke action movies nineties come social platf
orms change music film emergence rapper turn movie star full swing act take back seat man overpower regional accent transparent act one many ice movies s
aw kid love watch later cringe bill paxton william sadler firemen basic live burn build tenant flame hand map gold implications hand walter quickly neatl
y set main character location fault everyone involve turn lame performances ice cube must red hot time enjoy career rappers opinion fell flat movie ninet
y minutes one guy ridiculously turn back guy point find lock multiple state disbelief movie not documentary wont waste time recount stupid plot twist mov
ie many lead nowhere get feel watch everyone set sord confuse play things cuff two things still enjoy one involve scene needle sadler huge pistol bottom
line movie like domino pizza yeah ill eat hungry feel like cook well aware taste like crap star meh
```

Σχήμα Α'

Στο Σχήμα Α' παρουσιάζεται χαρακτηριστικό παράδειγμα κριτικής πριν και μετά την προεπεξεργασία. Παρατηρείται ότι, παρότι το κείμενο έχει απλοποιηθεί σημαντικά, το βασικό νόημα και η συναισθηματική πληροφορία διατηρούνται.

Εξαγωγή Χαρακτηριστικών

4.1 Αναπαράσταση με TF-IDF

Για την αριθμητική αναπαράσταση του κειμένου χρησιμοποιήθηκε η μέθοδος TF-IDF. Η μέθοδος αυτή αποδίδει μεγαλύτερη βαρύτητα σε λέξεις που είναι διακριτές για συγκεκριμένα έγγραφα και μικρότερη βαρύτητα σε λέξεις που εμφανίζονται πολύ συχνά στο σύνολο των δεδομένων.

Χρησιμοποιήθηκαν τόσο μονογράμματα όσο και διαγράμματα (n_gram range=(1,2)) ώστε να ληφθούν υπόψη απλές τοπικές συσχετίσεις μεταξύ διαδοχικών λέξεων. Παράλληλα, εφαρμόστηκαν τα φίλτρα min_df=10 και max_df=0.9 για την απομάκρυση πολύ σπάνιων και συχνών όρων. Η τελική αυτή αναπαράσταση οδήγησε σε έναν πίνακα διαστάσεων 100.000 x 163.495 ο οποίος δημιούργησε έναν αραιό, υψηλής διάστασης χώρο χαρακτηριστικών με περισσότερα από 160.000 χαρακτηριστικά, γεγονός που καθιστά αναγκαία τη χρήση μοντέλων ικανών να χειριστούν τέτοιες αναπαραστάσεις.

4.2 Word Embeddings με Word2Vec

Παράλληλα, εξετάστηκε και η χρήση κατανεμημένων αναπαραστάσεων λέξεων μέσω Word2Vec. Εκπαιδεύτηκε μοντέλο Skip-gram πάνω στο καθαρισμένο σύνολο δεδομένων, παράγοντας διανύσματα λέξεων 200 διαστάσεων. Για την αναπαράσταση κάθε κριτικής, υπολογίστηκε ο μέσος όρος των διανυσμάτων των λέξεων που την αποτελούν, δημιουργώντας έτσι πυκνά διανύσματα εγγράφων.

Η ποιοτική αξιολόγηση των embeddings έδειξε ότι λέξεις με παρόμοιο συναισθηματικό φορτίο παρουσιάζουν υψηλή συνημιτονοειδή ομοιότητα. Στον Πίνακα 3 παρουσιάζονται ενδεικτικά παραδείγματα σημασιολογικής εγγύτητας μεταξύ θετικών και αρνητικών όρων, γεγονός που επιβεβαιώνει ότι το μοντέλο Word2Vec έχει μάθει χρήσιμες σημασιολογικές σχέσεις.

Πίνακας Β’: Ενδεικτικά παραδείγματα σημασιολογικής εγγύτητας λέξεων (Word2Vec)

Λέξη αναφοράς	**Πλησιέστερες λέξεις**
bad	horrible (0.73), terrible (0.73), awful (0.69), lousy (0.63)
great	decent (0.74), excellent (0.62), nice (0.60), fine (0.59)

Ο Πίνακας Β’ παρουσιάζει ενδεικτικά αποτελέσματα από το εκπαιδευμένο μοντέλο Word2Vec. Παρατηρείται ότι λέξεις με παρόμοιο συναισθηματικό φορτίο εμφανίζουν υψηλή σημασιολογική εγγύτητα, γεγονός που επιβεβαιώνει ότι τα embeddings αποτυπώνουν επιτυχώς σχέσεις συναισθήματος στο γλωσσικό χώρο.

Παρότι το Word2Vec παρείχε σημασιολογικά συνεκτικά embeddings, η τελική επιλογή αναπαράστασης ήταν η TF-IDF. Το συμπέρασμα αυτό προκύπτει, καθώς σαν μέθοδος παρουσιάζει σταθερότερη απόδοση και μικρότερο υπολογιστικό κόστος σε κλασικούς αλγορίθμους ταξινόμησης. Επίσης, έννοιες όπως good και bad μπορεί να βγουν πολύ κοντά (λόγω παρόμοιου περιεχομένου).Τέλος σε σύγκριση με Word2Vec,χρειάζονται λιγότεροι υπερπαραμέτροι και δεν χρειάζεται εκπαίδευση embeddings.

4.3 Μείωση Διαστάσεων με PCA

Για τον περιορισμό της διαστασιμότητας και του υπολογιστικού κόστους, εφαρμόστηκε Ανάλυση Κύριων Συνιστωσών (PCA) στα διανύσματα Word2Vec μειώνοντας τη διάστασή τους από 200 σε 50. Η διαδικασία αυτή αποσκοπεί στη

διατήρηση της πιο σημαντικής πληροφορίας, μειώνοντας παράλληλα τον θόρυβο και βελτιώνοντας ενδεχομένως τη γενίκευση των μοντέλων.

Η μείωση διαστάσεων με PCA εφαρμόστηκε πειραματικά στα διανύσματα Word2Vec. Τα πειραματικά αποτελέσματα δεν έδειξαν σημαντική βελτίωση σε σχέση με την αρχική αναπαράσταση με στόχο τη διερεύνηση της επίδρασης της στην απόδοση των μοντέλων. Ωστόσο η προσέγγιση αυτή δεν χρησιμοποιήθηκε στα τελικά πειράματα, καθώς επιλέχθηκε η αναπαράσταση TF-IDF, η οποία παρουσίασε σταθερότερα και καλύτερα αποτελέσματα.

Μοντέλα Κατηγοριοποίησης

Δημιουργία Μοντέλων

5.1 Logistic Regression

Ως βασικό μοντέλο ταξινόμησης των κριτικών επιλέχθηκε το μοντέλο Λογιστικής Παλινδρόμησης σε συνδυασμό με αναπαράσταση με TF-IDF χαρακτηριστικά. Το μοντέλο αυτό αποτελεί κλασική και αποδοτική επιλογή για προβλήματα κατηγοριοποίησης κειμένου, ιδιαίτερα σε περιπτώσεις υψηλής διαστασιμότητας, λόγω της γραμμικής του φύσης και της δυνατότητας κανονικοποίησης.

Αρχικά επιλέχθηκαν οι ετικέτες θετικού και αρνητικού συναισθήματος οι οποίες μετατράπηκαν σε δυαδικές τιμές (0 για αρνητικές και 1 για θετικές).Στην συνέχεια, το σύνολο δεδομένων χωρίστηκε σε σύνολο εκπαίδευσης και ελέγχου με αναλογία 80%-20%. Για την εκπαίδευση και επεξεργασία του μοντέλου, χρησιμοποιήθηκε pipeline το οποίο περιλάμβανε μετασχηματισμό TF-IDF.

Αξιολόγηση Μοντέλου

Το μοντέλο Λογιστικής Παλινδρόμησης πέτυχε ακρίβεια 91% στο σύνολο ελέγχου με ισορροπημένες τιμές precision, recall και F1-score (0,91) για τις δύο κλάσεις. Το Σχήμα Γ' που απεικονίζει τον πίνακα σύγχυσης δείχνει ότι τα σφάλματα κατανέμονται σχετικά συμμετρικά μεταξύ ψευδώς θετικών και ψευδώς αρνητικών προβλέψεων και άρα το μοντέλο δεν παρουσιάζει μεροληψία υπέρ κάποιας κατηγορίας και επιτυγχάνει σταθερή απόδοση στην ταξινόμηση τόσο των θετικών όσο και των αρνητικών κριτικών. Συγκεκριμένα, από τις 5000 αρνητικές κριτικές ταξινομήθηκαν σωστά οι 4500 ενώ προβλέφθηκαν 500 λανθασμένα ως θετικές. Αντίστοιχα, από τις 5000 θετικές κριτικές, οι 4602 ταξινομήθηκαν σωστά και 398 προβλέφθηκαν ως αρνητικές.

```
Accuracy: 0.9102

Classification report:
              precision    recall  f1-score   support

         neg       0.92      0.90      0.91      5000
         pos       0.90      0.92      0.91      5000

    accuracy                           0.91     10000
   macro avg       0.91      0.91      0.91     10000
weighted avg       0.91      0.91      0.91     10000


Confusion matrix:
 [[4500  500]
 [ 398 4602]]
```

Το Σχήμα Γ' απεικονίζει τον πίνακα σύγχυσης για το μοντέλο Logistic Regression στο σύνολο ελέγχου. Το μοντέλο ταξινομεί σωστά τη συντριπτική πλειονότητα των θετικών και αρνητικών κριτικών, με περιορισμένο αριθμό ψευδώς θετικών και ψευδώς αρνητικών προβλέψεων.

5.2 XGBoost

Ως πιο προχωρημένο μοντέλο χρησιμοποιήθηκε ο αλγόριθμος XGBoost, μια ισχυρή ensemble μέθοδος βασισμένη σε gradient boosting δέντρων απόφασης. Το μοντέλο αυτό έχει τη δυνατότητα να αποτυπώνει πολύπλοκες και μη γραμμικές σχέσεις μεταξύ των χαρακτηριστικών και της μεταβλητής στόχου. Στην παρούσα εργασία, εξετάστηκε ως εναλλακτική προσέγγιση πάνω στα ίδια TF-IDF χαρακτηριστικά, ώστε να συγκριθεί η απόδοση του με το γραμμικό μοντέλο Λογιστικής Παλινδρόμησης.

Αξιολόγηση Μοντέλου

Στο σύνολο ελέγχου, το μοντέλο XGBoost πέτυχε ακρίβεια περίπου 86% , με εξίσου ισορροπημένες τιμές precision, recall και F1-score για τις δύο κλάσεις. Είναι χαμηλότερες σε σύγκριση με αυτές της Λογιστικής Παλινδρόμησης βέβαια και παρότι η απόδοσή του είναι σταθερή, υπολείπεται αυτής της Λογιστικής Παλινδρόμησης γεγονός που αποτυπώνεται και στον αντίστοιχο πίνακα σύγχυσης (Σχήμα 3). Παρατηρείται μεγαλύτερος αριθμός ψευδώς θετικών και ψευδώς αρνητικών προβλέψεων σε σχέση με το μοντέλο Λογιστικής Παλινδρόμησης , κάτι που αντανακλά τη χαμηλότερη συνολική απόδοση του XGBoost στο συγκεκριμένο πρόβλημα ταξινόμησης.

```
XGBoost Accuracy: 0.8679
              precision    recall  f1-score   support

           0       0.89      0.84      0.86      5000
           1       0.85      0.89      0.87      5000

    accuracy                           0.87     10000
   macro avg       0.87      0.87      0.87     10000
weighted avg       0.87      0.87      0.87     10000
```

```
Confusion Matrix:
[[4180  820]
 [ 564 4436]]
```

Το Σχήμα 3 παρουσιάζει τον πίνακα σύγχυσης του μοντέλου XGBoost στο σύνολο ελέγχου. Παρατηρείται αυξημένος αριθμός σφαλμάτων σε σχέση με τη Logistic Regression, γεγονός που αντανακλά τη χαμηλότερη συνολική απόδοση του μοντέλου στο συγκεκριμένο πρόβλημα.

Χρήση Cross-Validation για αξιολόγηση των μοντέλων

Για την αξιολόγηση της σταθερότητας των μοντέλων, εφαρμόστηκε 5-fold stratified cross-validation. Η Logistic Regression παρουσίασε μέση ακρίβεια 90.6% με πολύ μικρή τυπική απόκλιση (Πίνακας 6) γεγονός που υποδηλώνει καλή γενίκευση και απουσία έντονου overfitting. Το XGBoost εμφάνισε μέση ακρίβεια 85.9% (Πίνακας 7)με χαμηλή διακύμανση αλλά σε χαμηλότερο επίπεδο απόδοσης.

```
=== Cross-Validation Results (5-fold) ===
Accuracy : 0.9033 ± 0.0022
Precision: 0.8966 ± 0.0042
Recall   : 0.9117 ± 0.0027
F1-score : 0.9041 ± 0.0020
```

Πίνακας Γ': Αποτελέσματα 5-fold Cross-Validation για Λογιστική Παλινδρόμηση

Μετρικές	Αποτελέσματα
Accuracy	0.9033
Precision	0.8966
Recall	0.9117
F1-score	0.9041

Ο **Πίνακας Γ'** παρουσιάζει τα αποτελέσματα διασταυρωμένης επικύρωσης 5 πτυχών για το μοντέλο Logistic Regression. Η χαμηλή τυπική απόκλιση σε όλες τις μετρικές υποδηλώνει υψηλή σταθερότητα και καλή γενίκευση του μοντέλου.

```
=== XGBoost Cross-Validation Results (5-fold) ===
Accuracy : 0.8596 ± 0.0042
Precision: 0.8450 ± 0.0058
Recall   : 0.8809 ± 0.0041
F1-score : 0.8626 ± 0.0039
```

Πίνακας Δ': Αποτελέσματα 5-fold Cross-Validation για XGBoost

Μετρικές	**Αποτελέσματα**
Accuracy	0.8596
Precision	0.8450
Recall	0.8809
F1-score	0.8626

Ο **Πίνακας Δ'** παρουσιάζει τα αποτελέσματα διασταυρωμένης επικύρωσης για το μοντέλο XGBoost. Παρότι το μοντέλο παρουσιάζει σταθερή συμπεριφορά η απόδοσή του είναι χαμηλότερη σε σύγκριση με τη Logistic Regression για το συγκεκριμένο πρόβλημα κατηγοριοποίησης.

Συγκριτική Ανάλυση

Η σύγκριση των δύο μοντέλων έπειτα και από την χρήση Cross Validation δείχνει ότι παρά την αυξημένη πολυπλοκότητα του XGBoost , το απλούστερο γραμμικό μοντέλο Λογιστικής Παλινδρόμησης υπερέχει στο συγκεκριμένο πρόβλημα. Αυτό φαίνεται και από τις μετρικές απόδοσης που καταγράφονται στα πινακάκια Γ και Δ με την εφαρμογή και της επικυρωμένης διασταύρωσης. Η ακρίβεια για το μοντέλο Λογιστικής Παλινδρόμησης είναι ίση με 90% , την στιγμή που η αντίστοιχη για το μοντέλο XGBoost είναι ίση με 85% Το αποτέλεσμα αυτό είναι αναμενόμενο σε εφαρμογές ανάλυσης συναισθήματος με υψηλής διάστασης αραιές αναπαραστάσεις όπου τα γραμμικά μοντέλα συχνά γενικεύουν καλύτερα.

Συμπεράσματα και Μελλοντική Εργασία

Στην παρούσα εργασία αναπτύχθηκε ένα πλήρες σύστημα κατηγοριοποίησης κειμένων για ανάλυση συναισθήματος σε κριτικές IMDb. Η εκτενής προεπεξεργασία αποδείχθηκε καθοριστική λόγω της έντονης παρουσίας θορύβου στο αρχικό κείμενο. Η χρήση TF-IDF σε συνδυασμό με Logistic Regression παρείχε την καλύτερη συνολική απόδοση τόσο σε επίπεδο ακρίβειας όσο και σταθερότητας των αποτελεσμάτων. Η διερεύνηση Word2Vec embeddings ανέδειξε τη δυνατότητα μάθησης σημασιολογικών σχέσεων, ενώ η μείωση διαστάσεων με PCA προσέφερε επιπλέον κατανόηση του χώρου χαρακτηριστικών. Ως μελλοντική εργασία θα μπορούσε να εξεταστεί η χρήση σύγχρονων συμφραζόμενων embeddings όπως τα μοντέλα BERT καθώς και η περαιτέρω ανάλυση σφαλμάτων για περιπτώσεις ειρωνείας ή σύνθετων γλωσσικών δομών.